

Nama: Jihan Nisrina A. (24611013)

Clustering adalah proses untuk membagi semua data ke dalam grup atau biasa disebut dengan cluster berdasarkan pattern atau pola yang ada di dalam data.

Clustering	Klasifikasi
• hasilnya cluster • tidak ada label, hanya mengelompokkan data berdasarkan pattern atau pola yang ada di dalam data	• hasilnya kelas • ada label dari setiap kelas yang menandakan satu data itu termasuk di kelas mana

Clustering termasuk dalam unsupervised learning karena :

- tidak mempunyai ground truth (label) yang dapat dijadikan acuan apakah hasil klasifikasi yang dilakukan pada saat pelatihan benar atau tidak.
- hanya mengelompokkan data berdasarkan struktur atau pola yang ada di dalam data.
- tidak mempunyai target yang diprediksikan, tidak mempunyai target kelas yang pasti yang kita prediksikan hanya berupa kelompok-kelompok tanpa label. Jadi kita hanya mencoba untuk mengelompokkan data-data yang mirip ke dalam satu kelompok yang sama.

Cluster properties

- semua data yang ada di dalam satu cluster/kelompok mempunyai kemiripan antara satu dengan yang lainnya
- semua data yang berada pada cluster yang berbeda itu harus berbeda dari cluster yang lainnya (harus terpisah secara sempurna, hampir tidak ada bersinggungan)

Evaluasi clustering dilakukan tanpa label dapat menggunakan metrik seperti :

- Inertia

↳ melambangkan jarak intra cluster (jarak dari centroid cluster atau dari titik tengah cluster ke semua data yang ada dalam cluster tersebut). mengukur seberapa jauh persebaran antar poin dari data yang ada di tiap cluster. Karena inertia melambangkan jarak dan kita menginginkan cluster yang baik, inertia dicari dari yang sekecil yang memungkinkan. Jarak inertia kecil → tiap data dalam satu cluster itu rapat.

Sifat cluster yang baik :
data dalam cluster → harus mirip (jarak kecil)
antar cluster → harus berbeda (jarak besar)

data rapat $\rightarrow$ ciri-cirinya mirip.

- Dunn Index

$\rightarrow$ tidak hanya menghitung intra cluster distance tetapi juga menghitung inter cluster distance. Intra cluster distance jaraknya dari titik tengah cluster ke semua data yang ada di dalam cluster, sedangkan inter cluster distance jarak antara centroid cluster satu dengan centroid cluster dua. meminimalkan intra cluster dan memaksimalkan inter cluster.

$$\text{Dunn Index} = \frac{\min(\text{inter cluster distance})}{\max(\text{intra cluster distance})}$$