

UTS - MPML

Jihan Nisrina Andisti - 24611013

2026-05-17

Analisis clustering dilakukan untuk mengelompokkan kabupaten/kota di D.I. Yogyakarta berdasarkan indikator sosial-ekonomi dan pembangunan manusia.

Langkah pertama dataset diimpor ke dalam R dengan menggunakan fungsi 'read.csv()' untuk membaca file CSV yang telah disusun dari data BPS

```
cluster_diy <- read.csv("C:\\Users\\jihan nisrina andist\\OneDrive - Universitas Islam Indonesia\\Dokum  
cluster_diy
```

```
##      Kabupaten Kepadatan_Penduduk TPT Persentase_Kemiskinan IPM  
## 1 Kulon Progo          760 2.01          15.62 76.18  
## 2      Bantul          2008 3.62          11.66 82.05  
## 3 Gunungkidul          506 2.16          15.18 72.14  
## 4      Sleman          2033 4.13           7.46 85.71  
## 5  Yogyakarta         11562 5.80           6.26 89.10
```

Kemudian lakukan pengecekan struktur data

```
str(cluster_diy)
```

```
## 'data.frame':    5 obs. of  5 variables:  
## $ Kabupaten      : chr  "Kulon Progo" "Bantul" "Gunungkidul" "Sleman" ...  
## $ Kepadatan_Penduduk : int  760 2008 506 2033 11562  
## $ TPT              : num  2.01 3.62 2.16 4.13 5.8  
## $ Persentase_Kemiskinan: num  15.62 11.66 15.18 7.46 6.26  
## $ IPM              : num  76.2 82 72.1 85.7 89.1
```

```
summary(cluster_diy)
```

```
## Kabupaten      Kepadatan_Penduduk      TPT      Persentase_Kemiskinan
## Length:5      Min. : 506      Min. :2.010      Min. : 6.26
## Class :character 1st Qu.: 760      1st Qu.:2.160      1st Qu.: 7.46
## Mode :character Median : 2008      Median :3.620      Median :11.66
##               Mean : 3374      Mean :3.544      Mean :11.24
##               3rd Qu.: 2033      3rd Qu.:4.130      3rd Qu.:15.18
##               Max. :11562      Max. :5.800      Max. :15.62
##
## IPM
## Min. :72.14
## 1st Qu.:76.18
## Median :82.05
## Mean :81.04
## 3rd Qu.:85.71
## Max. :89.10
```

Langkah ini dilakukan agar memastikan data bernilai numerik dan juga memastikan bahwa data tidak memiliki nilai yang hilang atau missing value

Mengambil Variabel Numerik

```
data_numeric <- cluster_diy[,2:5]

data_numeric
```

```
## Kepadatan_Penduduk TPT Persentase_Kemiskinan IPM
## 1      760 2.01      15.62 76.18
## 2      2008 3.62      11.66 82.05
## 3      506 2.16      15.18 72.14
## 4      2033 4.13      7.46 85.71
## 5      11562 5.80      6.26 89.10
```

Karena clustering tidak menggunakan kolom kabupaten maka dari itu hanya diambil data numeriknya saja, dan data numerik berada dikolom 2 sampai 5

Standarisasi Data

```
data_scaled <- scale(data_numeric)

data_scaled
```

```
## Kepadatan_Penduduk TPT Persentase_Kemiskinan IPM
## [1,] -0.5644751 -0.98470395 1.01944447 -0.7034318
## [2,] -0.2949576 0.04878585 0.09859591 0.1468863
```

```
## [3,]          -0.6193288 -0.88841608          0.91712796 -1.2886593
## [4,]          -0.2895586  0.37616461         -0.87806166  0.6770676
## [5,]           1.7683200  1.44816957         -1.15710668  1.1681372
## attr(,"scaled:center")
##      Kepadatan_Penduduk          TPT Persentase_Kemiskinan
##           3373.800              3.544              11.236
##           IPM
##           81.036
## attr(,"scaled:scale")
##      Kepadatan_Penduduk          TPT Persentase_Kemiskinan
##           4630.496755          1.557829              4.300381
##           IPM
##           6.903298
```

Standarisasi dilakukan agar seluruh variabel memiliki skala yang sebanding sehingga tidak ada variabel yang mendominasi proses clustering, kalau tidak distandarisasi nanti clustering jadi bias

Menghitung Jarak

```
dist_matrix <- dist(data_scaled,
                     method = "euclidean")

dist_matrix
```

```
##           1           2           3           4
## 2 1.646737
## 3 0.604351 1.927265
## 4 2.726509 1.158516 2.965586
## 5 4.427296 2.972395 4.636680 2.388111
```

Hierarchial Clustering


```
hc <- hclust(dist_matrix,
             method = "ward.D2")

hc
```

```
##
## Call:
## hclust(d = dist_matrix, method = "ward.D2")
##
## Cluster method      : ward.D2
## Distance            : euclidean
## Number of objects: 5
```

Hierarchical clustering dilakukan menggunakan metode ward dengan jarak euclidean untuk mengelompokkan wilayah berdasarkan kemiripan karakteristik sosial dan ekonomi

```
plot(hc,  
     labels = cluster_diy$Kabupaten,  
     main = "Dendrogram Hierarchical Clustering",  
     xlab = "Kabupaten/Kota",  
     ylab = "Height",  
     sub = "")  
rect.hclust(hc,  
            k = 2,  
            border = "red")
```



Dendrogram digunakan untuk melihat struktur pengelompokan wilayah dan menentukan jumlah cluster yang terbentuk. Berdasarkan dendrogram hierarchical clustering, kabupaten/kota di D.I. Yogyakarta terbagi menjadi dua cluster utama. Cluster pertama terdiri atas Kulon Progo dan Gunungkidul yang memiliki karakteristik tingkat kemiskinan relatif lebih tinggi, IPM lebih rendah, serta kepadatan penduduk yang lebih rendah dibanding wilayah lainnya. Sementara itu, cluster kedua terdiri atas Bantul, Sleman, dan Kota Yogyakarta yang menunjukkan karakteristik wilayah dengan tingkat pembangunan manusia lebih tinggi, tingkat kemiskinan lebih rendah, dan kondisi sosial-ekonomi yang lebih baik. Selain itu, Bantul dan Sleman memiliki jarak yang paling dekat pada dendrogram sehingga menunjukkan tingkat kemiripan karakteristik yang tinggi.

```
cluster_diy$Cluster_HC <- cutree(hc, k = 2)

cluster_diy$Label_HC <- ifelse(cluster_diy$Cluster_HC == 1,
                               "Wilayah Berkembang",
                               "Wilayah Maju")

cluster_diy
```

```
##      Kabupaten Kepadatan_Penduduk TPT Persentase_Kemiskinan IPM Cluster_HC
## 1 Kulon Progo           760 2.01           15.62 76.18           1
## 2 Bantul              2008 3.62           11.66 82.05           2
## 3 Gunungkidul         506 2.16           15.18 72.14           1
## 4 Sleman              2033 4.13           7.46 85.71           2
## 5 Yogyakarta         11562 5.80           6.26 89.10           2
##      Label_HC
## 1 Wilayah Berkembang
## 2 Wilayah Maju
## 3 Wilayah Berkembang
## 4 Wilayah Maju
## 5 Wilayah Maju
```

Hasil hierarchical clustering kemudian digunakan untuk membentuk kelompok wilayah menggunakan fungsi ‘cutree()’. Pada penelitian kali ini dipilih sebanyak 2 cluster berdasarkan hasil dendrogram. Selanjutnya setiap cluster diberikan label interpretatif agar lebih mudah dipahami, yaitu “wilayah berkembang” dan “wilayah maju”. Label tersebut diberikan berdasarkan karakteristik masing-masing cluster. Wilayah dengan tingkat kemiskinan lebih tinggi dan IPM lebih rendah dikategorikan sebagai “Wilayah Berkembang”, sedangkan wilayah dengan tingkat pembangunan manusia lebih tinggi dan kondisi sosial-ekonomi yang lebih baik dikategorikan sebagai “Wilayah Maju”.

K-Means Clustering

Metode K-Means Clustering digunakan untuk mengelompokkan wilayah berdasarkan centroid cluster yang terbentuk. Pada penelitian ini digunakan sebanyak 2 cluster agar hasil pengelompokan lebih konsisten dengan hasil hierarchical clustering dan lebih mudah diinterpretasikan.

Menentukan seed agar hasil tetap atau konsisten

```
set.seed(123)
```

Membuat model K-Means

```
kmeans_result <- kmeans(data_scaled,
                          centers = 2,
                          nstart = 25)
kmeans_result

## K-means clustering with 2 clusters of sizes 3, 2
##
## Cluster means:
##   Kepadatan_Penduduk      TPT Persentase_Kemiskinan      IPM
## 1      -0.4929205 -0.6081114      0.6783894 -0.6150683
## 2       0.7393807  0.9121671     -1.0175842  0.9226024
##
## Clustering vector:
## [1] 1 1 1 2 2
##
## Within cluster sum of squares by cluster:
```

```
## [1] 2.263778 2.851537
## (between_SS / total_SS = 68.0 %)
##
## Available components:
##
## [1] "cluster"      "centers"      "totss"        "withinss"     "tot.withinss"
## [6] "betweenss"    "size"         "iter"         "ifault"
```

Metode K-Means digunakan untuk membagi wilayah ke dalam beberapa cluster berdasarkan centroid yang terbentuk.

Hasil clustering kemudian ditambahkan ke dalam dataset untuk melihat pembagian cluster pada masing-masing kabupaten/kota.

```
cluster_diy$Cluster_KMeans <- kmeans_result$cluster
```

```
cluster_diy
```

```
##      Kabupaten Kepadatan_Penduduk TPT Persentase_Kemiskinan IPM Cluster_HC
## 1 Kulon Progo          760 2.01              15.62 76.18          1
## 2      Bantul          2008 3.62              11.66 82.05          2
## 3 Gunungkidul          506 2.16              15.18 72.14          1
## 4      Sleman          2033 4.13              7.46 85.71          2
## 5 Yogyakarta          11562 5.80             6.26 89.10          2
##      Label_HC Cluster_KMeans
## 1 Wilayah Berkembang          1
## 2      Wilayah Maju            1
## 3 Wilayah Berkembang          1
## 4      Wilayah Maju            2
## 5      Wilayah Maju            2
```

Setiap cluster kemudian diberikan label interpretatif berdasarkan karakteristik sosial-ekonomi wilayah yang terbentuk.

```
cluster_diy$Label_KMeans <- ifelse(cluster_diy$Cluster_KMeans == 1,
                                   "Wilayah Berkembang",
                                   "Wilayah Maju")
```

```
cluster_diy
```

```
##      Kabupaten Kepadatan_Penduduk TPT Persentase_Kemiskinan IPM Cluster_HC
## 1 Kulon Progo          760 2.01              15.62 76.18          1
## 2      Bantul          2008 3.62              11.66 82.05          2
## 3 Gunungkidul          506 2.16              15.18 72.14          1
## 4      Sleman          2033 4.13              7.46 85.71          2
## 5 Yogyakarta          11562 5.80             6.26 89.10          2
##      Label_HC Cluster_KMeans      Label_KMeans
```

## 1 Wilayah Berkembang	1 Wilayah Berkembang
## 2 Wilayah Maju	1 Wilayah Berkembang
## 3 Wilayah Berkembang	1 Wilayah Berkembang
## 4 Wilayah Maju	2 Wilayah Maju
## 5 Wilayah Maju	2 Wilayah Maju

```
library(factoextra)
```

```
## Warning: package 'factoextra' was built under R version 4.4.3
```

```
## Loading required package: ggplot2
```


```
## Warning: package 'ggplot2' was built under R version 4.4.3
```

```
## Welcome to factoextra!
```

```
## Want to learn more? See two factoextra-related books at https://www.datanovia.com/en/product/practice
```

Visualisasi cluster digunakan untuk melihat pola pengelompokan wilayah berdasarkan hasil K-Means Clustering.


```
fviz_cluster(kmeans_result,
             data = data_scaled,
             geom = "point",
             ellipse = FALSE,
             main = "Visualisasi K-Means Clustering")
```



Berdasarkan visualisasi K-Means Clustering, kabupaten/kota di D.I. Yogyakarta terbagi menjadi dua cluster utama. Cluster pertama menunjukkan wilayah dengan kondisi sosial-ekonomi yang relatif lebih rendah, sedangkan cluster kedua menunjukkan wilayah dengan tingkat pembangunan yang lebih baik. Jarak antar titik menunjukkan tingkat kemiripan karakteristik antar wilayah.

Elbow Method


```
fviz_nbclust(data_scaled,
             kmeans,
             method = "wss",
             k.max = 4) +
ggtitle("Elbow Method")
```



Elbow method digunakan untuk menentukan jumlah cluster optimal pada metode K-Means. Berdasarkan grafik elbow method, jumlah cluster optimal diperoleh pada $k = 2$ karena terjadi penurunan nilai total within sum of squares yang cukup tajam dari $k = 1$ ke $k = 2$ dan mulai melandai setelahnya.

Silhouette Method

```
fviz_nbclust(data_scaled,
             kmeans,
             method = "silhouette",
             k.max = 4) +
ggtitle("Silhouette Method")
```



Silhouette method digunakan untuk mengevaluasi kualitas cluster yang terbentuk. Berdasarkan grafik silhouette method, nilai silhouette tertinggi diperoleh pada $k = 3$. Namun, penelitian ini tetap menggunakan 2 cluster karena hasil pengelompokan lebih mudah diinterpretasikan dan konsisten dengan hierarchical clustering.

```
library(cluster)
```

```
## Warning: package 'cluster' was built under R version 4.4.3
```

```
sil <- silhouette(kmeans_result$cluster,
                  dist(data_scaled))
mean(sil[,3])
```

```
## [1] 0.3696247
```

Menghitung rata-rata setiap cluster

```
aggregate(data_numeric,
          by = list(Cluster = cluster_diy$Cluster_KMeans),
          mean)
```

```
##   Cluster Kepadatan_Penduduk      TPT Persentase_Kemiskinan   IPM
## 1      1      1091.333 2.596667      14.15333 76.790
## 2      2      6797.500 4.965000      6.86000 87.405
```

Hasil evaluasi menggunakan silhouette score memperoleh nilai sebesar 0,37 yang menunjukkan bahwa kualitas clustering tergolong cukup baik.

```
library(clusterSim)
```

```
## Warning: package 'clusterSim' was built under R version 4.4.3
```

```
## Loading required package: MASS
```

Menghitung DBI

```
index.DB(data_scaled,
         cluster_diy$Cluster_KMeans)$DB
```

```
## [1] 0.6848962
```

Hasil evaluasi menggunakan Davies-Bouldin Index (DBI) menghasilkan nilai sebesar 0,685. Nilai yang relatif kecil menunjukkan bahwa cluster yang terbentuk memiliki pemisahan yang cukup baik.

##Kesimpulan

#Berdasarkan hasil analisis clustering, kabupaten/kota di D.I. Yogyakarta dapat dikelompokkan menjadi dua cluster utama, yaitu wilayah berkembang dan wilayah maju. Wilayah berkembang memiliki tingkat kemiskinan yang relatif lebih tinggi dan nilai IPM yang lebih rendah, sedangkan wilayah maju memiliki kondisi sosial-ekonomi dan pembangunan manusia yang lebih baik. Berdasarkan hasil evaluasi menggunakan silhouette score dan Davies-Bouldin Index, metode clustering yang digunakan mampu menghasilkan pengelompokan wilayah yang cukup baik.

Sumber Data

#Data diperoleh dari publikasi “Provinsi Daerah Istimewa Yogyakarta Dalam Angka 2025” yang diterbitkan oleh Badan Pusat Statistik (BPS).